

Dimension-free moment GMM

Экспериментальный отчёт

От глобального обзора модели до проверки устойчивости к contamination и направленной асимметрии

Охват отчёта

Пять последовательных экспериментов, 74 сценария данных и пять взаимосвязанных семейств абляций. В отчёте сохранены только интерпретируемые срезы таблиц, но описаны все участвовавшие модели.

30 июля 2026 г.

Репозиторий: /Users/borishukov/Projects/gmm_clean

Содержание

1	Краткое резюме	3
2	Модель, метрики и правила чтения результатов	3
2.1	Что оптимизирует moment-модель	3
2.2	Метрики	4
2.3	Правила агрегации и ограничения	4
3	Каталог всех участвовавших моделей	5
3.1	Варианты первого global sweep	5
3.2	Общий каталог последующих абляций	6
4	Эксперимент 1: глобальный обзор модели	6
4.1	Постановка	6
4.2	Сокращённая таблица результатов	6
4.3	Что выяснили отдельные абляции	7
5	Эксперимент 2: clean robustness и moment ablation	7
5.1	Постановка	7
5.2	Факториал стабилизации	8
5.3	Сетка вторых моментов	8
5.4	Sample-size ladder	8
6	Эксперимент 3: contamination robustness	9
6.1	Постановка	9
6.2	Средние по типам contamination	9
7	Эксперимент 4: density-based выбор тестовых центров	10
7.1	Постановка	10
7.2	Средний эффект доли центров	10
7.3	Зависимость от типа contamination	10
8	Эксперимент 5: направленная асимметрия компонент	11
8.1	Постановка	11
8.2	Общий результат	11
8.3	Взаимодействие sample regime и separation	12
8.4	Эффект направления	12
8.5	Статистические вырождения	12
9	Сквозные выводы о работе метода	13
9.1	Что подтверждено	13

9.2	Что не подтверждено	13
9.3	Где остаётся положительная гипотеза	13
10	Рекомендуемая следующая программа экспериментов	13
11	Карта артефактов	14

1 Краткое резюме

Цель серии экспериментов --- понять, какие части обобщённой моментной модели действительно улучшают оценивание гауссовских смесей, и проверить гипотезу, что критерий на локализованных тестовых функциях устойчивее likelihood-based методов при малой выборке и misspecification.

Этап	Главный вопрос	Краткий ответ
Global sweep	Какие режимы новой модели вообще жизнеспособны?	Стабилизация вокруг KMeans и большое число тестовых центров критичны. ЕМ остаётся общим лидером.
Clean robustness	Что дают mean penalty, near-mean centers и вторые моменты?	Основной вклад даёт mean penalty; near-mean centers полезны как дополнение. Усиление вторых моментов улучшает нестабилизированную модель, но не закрывает разрыв с ЕМ.
Contamination	Устойчив ли метод к тяжёлым хвостам и выбросам?	ЕМ лучше по плотности и параметрам в среднем. Moment-метод показывает интересное преимущество по ARI на некоторых тяжёлых Student- t сценариях.
Density centers	Помогает ли отбрасывать разреженные центры тестовых функций?	Иногда --- особенно для Student- t и нестабильной $n_2 = 3$ модели. Универсального улучшения нет; агрессивная фильтрация не оправдана.
Directional skewness	Побеждает ли moment-метод ЕМ при асимметричных компонентах?	Нет в исследованном режиме. ЕМ выигрывает True KL и восстановление компонент; разрыв растёт при малой выборке и неравных весах.

Главный содержательный вывод. Собранная модель уже является рабочим оценщиком: в сложных balanced сценариях она существенно улучшает KMeans и по ARI приближается к ЕМ. Однако имеющиеся данные не подтверждают общее превосходство над ЕМ по устойчивости. Наиболее перспективная ниша, которую стоит проверять дальше, --- асимметричные тяжёлые хвосты и gross contamination, а не просто light-tailed skewness.

Практический shortlist моделей.

- `stab_balanced_both` --- основной вариант, когда важны density fit и общая стабильность;
- `stab_n3_w025_near` --- наиболее разумный вариант для структурного восстановления компонент;
- `stab_n3_w025_both` --- дополнительный вариант для Sliced Wasserstein и проверки трёх вторых направлений;
- `em_kmeans_reg1e6` и `em_kmeans_reg1e2` --- обязательные likelihood baselines;
- `kmeans_spherical` --- контроль качества общей инициализации.

2 Модель, метрики и правила чтения результатов

2.1 Что оптимизирует moment-модель

Модель сопоставляет наблюдаемые ответы локализованных гауссовских тестовых функций с их аналитическим ожиданием под сферической Gaussian mixture. В конфигурации можно независимо выбирать количество нулевых, первых и вторых моментов, направления второго поряд-

ка, веса семейств моментов, стратегию работы с bandwidth s , геометрическую оптимизацию и ограничения на амплитуды.

В окончательной базовой конфигурации используются:

- KMeans-инициализация с десятью рестартами;
- автоматический выбор bandwidth;
- simplex-ограничение на веса смеси;
- совместная оптимизация всех s ;
- покомпонентная геометрическая оптимизация;
- нормировка loss каждого порядка по числу его тестовых функций.

Два механизма стабилизации имеют разный смысл:

- **mean penalty** штрафует удаление средних от KMeans-инициализации;
- **near-mean centers** добавляет тестовые центры около текущих средних и локально усиливает идентификацию компонент.

2.2 Метрики

Для первых четырёх экспериментов **Forward KL** вычисляется относительно истинной гауссовской смеси или её moment-matched Gaussian core. В contamination-экспериментах это *не* KL между фактическим негауссовским распределением наблюдений и найденной моделью.

В directional-skewness эксперименте добавлены:

- **True Forward KL** --- Monte Carlo оценка $\mathbb{E}_P[\log p(X) - \log q(X)]$ для точной skewed-плотности;
- **Held-out NLL** на общей независимой выборке;
- **Sliced W2** по случайным и истинным skewness-направлениям;
- **Energy Distance** между обучающей X и выборкой из модели;
- **Conditional NLL** после сопоставления истинных и найденных компонент.

Остальные метрики:

- **Weights TV** --- total variation между векторами весов;
- **Means Error** --- нормированная по масштабу компонент ошибка средних;
- **Covariance Error** --- аффинно-инвариантная ошибка ковариаций;
- **ARI** --- permutation-invariant качество кластеризации.

2.3 Правила агрегации и ограничения

- Во всех пяти финальных наборах каждая строка имеет ок=1. Строки с падениями не входят в таблицы.
- В отчёте не анализируется runtime: на этой стадии исследуется качество, а не вычислительный бюджет.
- Средние по разнородным сценариям используются как описательная сводка; основной смысл имеют сравнения внутри сценария и средние ранги.

- Сохранены mean/median/std/IQR, но не индивидуальные paired результаты. Поэтому формальные доверительные интервалы для разности методов восстановить нельзя.
- Три model seeds на одном dataset seed не являются тремя независимыми наборами данных. Стандартные отклонения в CSV нельзя напрямую интерпретировать как стандартную ошибку среднего.
- Выбор ``лучшей moment-модели`` после просмотра результатов является оптимистичным; для подтверждающего эксперимента shortlist должен быть зафиксирован заранее.

3 Каталог всех участвовавших моделей

3.1 Варианты первого global sweep

Имя модели	Изменение относительно базовой moment-конфигурации
moment_first_only3	Только три первых направления: $(n_0, n_1, n_2) = (0, 3, 0)$.
moment_second_only3	Только три вторых направления: $(0, 0, 3)$.
moment_zero1_first2	Нулевой и два первых момента: $(1, 2, 0)$.
moment_first2_second1	Два первых и один второй момент: $(0, 2, 1)$.
moment_zero1_second2	Нулевой и два вторых момента: $(1, 0, 2)$.
moment_all_balanced	База $(1, 1, 1)$ с равными весами семейств.
moment_all_first_rich	$(1, 3, 1)$: больше первых направлений.
moment_all_second_rich	$(1, 1, 3)$: больше вторых направлений.
moment_all_cross_second	$(1, 1, 1)$, второй момент использует два независимых направления.
moment_all_second_weight025	База с весом второго семейства 0.25.
moment_all_second_weight4	База с весом второго семейства 4.0.
moment_all_non_negative	Неотрицательные амплитуды без simplex-связи во время оптимизации.
moment_all_sequential_s	Последовательная оптимизация по bandwidth s .
moment_all_joint_geometry	Одновременная геометрическая оптимизация всех компонент.
moment_all_centers50_data	50 центров, выбранных непосредственно из данных.
moment_all_centers50_noisy_auto	50 noisy-data центров; шум выбирается автоматически.
moment_all_centers200_noisy_auto	То же, но 200 центров.
moment_all_stabilized	База + near-mean centers с ratio 1.0 + mean penalty 10^{-3} .
sklearn_gmm_kmeans	Сферическая sklearn GMM/EM, KMeans init, $\text{reg_covar}=1e-6$.
sklearn_kmeans	Сферический KMeans-контроль с эмпирическими весами и дисперсиями.

3.2 Общий каталог последующих абляций

Имена	Смысл
stab_balanced_none, ..._penalty, ..._near, ..._both	Факториал для $(n_0, n_1, n_2) = (1, 1, 1)$: без стабилизации; только mean penalty; только near-mean centers; оба механизма.
second_n1_w010 ...second_n5_w050	Полная сетка $n_2 \in \{1, 3, 5\}$ и $w_2 \in \{0.10, 0.25, 0.50\}$ при одном нулевом и одном первом моменте.
second_n3_w025 и stab_n3_w025_penalty/near/both	Повторный стабилизационный факториал в выбранной точке $n_2 = 3, w_2 = 0.25$.
second_n5_w050	Сильная граница second-moment grid, использованная в contamination-тестах.
moment_first_only3	Контроль без нулевых и вторых моментов.
em_kmeans_reg1e6, em_kmeans_reg1e2	Сферическая EM с KMeans init и регуляризацией ковариации 10^{-6} или 10^{-2} .
kmeans_spherical	Инициализационный контроль без последующей EM/moment-оптимизации.

В clean robustness эксперименте участвовали все четыре balanced-варианта, все девять точек second-moment grid, три стабилизированных варианта $n_2 = 3, w_2 = 0.25$, first-only контроль и три baseline --- всего 20 моделей.

В contamination и directional-skewness экспериментах использован сокращённый набор из десяти moment-моделей: stab_balanced_none/penalty/near/both, second_n3_w025, stab_n3_w025_penalty/near/both, second_n5_w050, moment_first_only3; плюс две EM и KMeans --- всего 13.

В density-center эксперименте использованы пять семейств: stab_balanced_both, stab_balanced_penalty, stab_balanced_near, stab_n3_w025_both, stab_balanced_none. Каждое семейство протестировано с test_center_fraction $f \in \{1.0, 0.9, 0.5, 0.3\}$; суффиксы f100/f090/f050/f030 однозначно описывают все 20 moment-моделей. Дополнительно включены те же три baseline.

4 Эксперимент 1: глобальный обзор модели

Конфиг: optimization_moments_global_sweep.yaml | каталог результатов: optimization_moments_global_sweep/.

4.1 Постановка

Эксперимент охватывает 20 сценариев: решётку $d \in \{3, 30\}$, $n \in \{60, 500\}$ и easy/hard separation; стресс по дисперсиям и весам; смеси из пяти компонент; диагональную и полную ковариации при сферической оцениваемой модели. Для каждого сценария использовано 10 dataset seeds и 2 model seeds. Всего сравнивались 18 moment-вариантов и две sklearn модели.

4.2 Сокращённая таблица результатов

Модель	KL ↓	TV ↓	Mean ↓	Cov ↓	ARI ↑
EM	0.325	0.132	0.220	0.203	0.641
KMeans	0.404	0.163	0.253	0.229	0.585
all stabilized	0.391	0.159	0.240	0.209	0.600
first only 3	0.407	0.165	0.243	0.216	0.589
all second rich	0.517	0.163	0.261	0.226	0.592
all balanced	0.695	0.164	0.275	0.267	0.585

Это средние по всем 20 сценариям; они нужны для общей ориентации, а не для формального рейтинга. По среднему внутрисценарному рангу EM также первая, `moment_all_stabilized` --- лучшая `moment`-модель.

EM выиграла Forward KL в 13 из 20 сценариев; `first-only moment` --- в четырёх. `Stabilized moment` уступает EM, но улучшает исходную `balanced` модель по KL на 44%, по `mean error` на 13% и по ARI примерно на 0.016.

4.3 Что выяснили отдельные абляции

- **Стабилизация важнее выбора порядка моментов.** `all_stabilized` имеет KL 0.391 против 0.695 у `all_balanced`.
- **Первые моменты особенно информативны.** `First-only` даёт KL 0.407 и `mean error` 0.243.
- **Дополнительные вторые направления полезнее одного:** `second-rich` улучшает `balanced` KL с 0.695 до 0.517.
- **Два независимых `second-order` направления** дают умеренное улучшение KL (0.612), но не меняют общий вывод.
- **Слишком большой `second weight` вреден:** $w_2 = 4$ даёт KL 0.730, а $w_2 = 0.25$ --- 0.644.
- **Joint geometry нестабилен:** `mean error` 1.074 против 0.275 у покомпонентной оптимизации.
- **Последовательная оптимизация по s уступает совместной:** KL 0.906 против 0.695.
- **Число центров существенно:** 50 центров дают KL 0.73--0.86, 200 noisy centers --- 0.499.
- **Non-negative амплитуды не дают устойчивого преимущества** и теряют прямую связь с нормированной смесью во время оптимизации; `simplex` остаётся предпочтительным дефолтом.

Решение по результатам. Зафиксировать `simplex`, `joint-s`, `component geometry` и достаточно большое число тестовых центров. Разделить стабилизацию на `mean penalty` и `near-mean centers` и отдельно исследовать количество/вес вторых моментов.

5 Эксперимент 2: clean robustness и moment ablation

Конфиг: `moments_robustness_ablation.yaml` | каталог результатов: `moments_robustness_ablation/`.

5.1 Постановка

18 чистых гауссовских сценариев включают `sample-size ladder` $n \in \{30, 60, 200, 500\}$, `dimension stress` до $d = 60$, стресс по дисперсиям и весам, `separation ladder`, пять компонент, несферические ковариации и `easy calibration`. Использовано 30 dataset seeds и 3 model seeds.

Эксперимент отвечает на два заранее поставленных вопроса:

1. разделить эффекты `mean penalty` и `near-mean centers`;
2. проверить сетку $n_2 \in \{1, 3, 5\}$, $w_2 \in \{0.10, 0.25, 0.50\}$.

5.2 Факториал стабилизации

Модель	KL ↓	TV ↓	Mean ↓	Cov ↓	ARI ↑
balanced none	1.972	0.215	0.448	1.722	0.499
balanced penalty	0.937	0.205	0.332	0.674	0.557
balanced near	1.851	0.208	0.414	1.324	0.511
balanced both	0.888	0.204	0.329	0.704	0.560
$n_2 = 3$ none	1.654	0.222	0.444	1.419	0.500
$n_2 = 3$ penalty	0.972	0.212	0.333	0.742	0.547
$n_2 = 3$ near	1.500	0.221	0.383	1.038	0.512
$n_2 = 3$ both	0.968	0.213	0.331	0.773	0.547

Mean penalty является главным стабилизирующим фактором. Near-mean centers сами по себе улучшают исходную модель гораздо слабее, но вместе со штрафом дают небольшое дополнительное улучшение KL, весов, средних и ARI. У $n_2 = 3$ добавление near centers поверх penalty почти нейтрально по ARI.

5.3 Сетка вторых моментов

n_2	w_2	KL ↓	ARI ↑	n_2	w_2	KL ↓	ARI ↑
1	0.10	1.830	0.481	3	0.10	1.674	0.490
1	0.25	1.886	0.488	3	0.25	1.654	0.500
1	0.50	1.926	0.494	3	0.50	1.637	0.508
5	0.10	1.578	0.496	5	0.25	1.517	0.508
5	0.50	1.455	0.518				

В нестабилизированной сетке больше направлений последовательно улучшает результат. При $n_2 = 3$ и 5 больший вес второго семейства также полезен. Однако даже лучшая точка $n_2 = 5, w_2 = 0.5$ заметно хуже стабилизированной balanced-модели. Следовательно, вторые моменты содержат полезный сигнал, но не заменяют регуляризацию геометрии.

5.4 Sample-size ladder

	EM reg 10^{-2}		balanced both	
n	KL ↓	ARI ↑	KL ↓	ARI ↑
30	1.194	0.477	1.514	0.471
60	0.495	0.644	0.718	0.570
200	0.091	0.780	0.246	0.694
500	0.035	0.788	0.147	0.717

Гипотеза о более мягкой деградации moment-метода при малом n не подтвердилась. При $n = 30$ методы близки по ARI, но с ростом данных EM использует дополнительную информацию значительно эффективнее. Dimension stress усиливает этот вывод: при $d = n = 60$ EM имеет KL 4.14 и ARI 0.468, balanced-both --- KL 5.95 и ARI 0.380.

При этом moment-оптимизация существенно лучше простого KMeans в большинстве сложных сценариев. Это подтверждает, что критерий обучает модель, а не только наследует сильную инициализацию.

Решение по результатам. Основным вариантом оставить `stab_balanced_both`; сохранить `stab_n3_w025_both/near` как структурные альтернативы. Гипотезу превосходства над ЕМ перенести из чистого `small-n` режима в явное `misspecification` и `contamination`.

6 Эксперимент 3: contamination robustness

Конфиг: `moments_contamination_robustness.yaml` | каталог результатов: `moments_contamination_robustness/`.

6.1 Постановка

12 сценариев образованы четырьмя типами отклонения от Gaussian mixture:

- Student- t компоненты с $\nu \in \{3, 5, 10\}$;
- component-wise variance contamination;
- diffuse uniform background;
- удалённые radial outliers.

Для каждого сценария использовано 20 dataset seeds и 3 model seeds. Parameter metrics и старая Forward KL направлены на чистую Gaussian core. Для явных outliers ARI считается только по clean observations; у Student- t метки определены для всех наблюдений.

6.2 Средние по типам contamination

	EM reg 10^{-2}		balanced both	
Тип	KL ↓	ARI ↑	KL ↓	ARI ↑
Radial	0.491	0.502	0.651	0.423
Student- t	0.733	0.442	1.108	0.500
Uniform	0.722	0.465	1.082	0.403
Variance	0.630	0.397	0.766	0.348

ЕМ сохраняет преимущество по Gaussian-core density и параметрам почти во всех группах. Moment-модель не демонстрирует общей B-robustness: удалённые точки всё ещё влияют на выбранные средние и дисперсии через empirical moment responses и KMeans init.

Однако Student- t даёт важное исключение: по ARI moment-метод в среднем лучше ЕМ. Особенно заметен сценарий $\nu = 3$:

Сценарий	Лучший moment ARI	Лучший EM ARI
Student- t , $\nu = 10$, $d = 10$	0.670	0.648
Student- t , $\nu = 3$, $d = 10$	0.533	0.342
Student- t , $\nu = 5$, $d = 30$	0.309	0.336
Radial, 10%, radius 10--16	0.129	0.079
Uniform, 10%, padding 8	0.115	0.063
Variance, 10%, inflation 100	0.063	0.046

Последние три преимущества достигаются при очень низком абсолютном ARI: это скорее более медленное разрушение, чем практически хорошая кластеризация. А вот разница на Student- t с $\nu = 3$ содержательна и поддерживает гипотезу о потенциальном преимуществе bounded/localized моментов при тяжёлых хвостах.

Из moment-моделей наиболее устойчив `stab_balanced_both`. Mean penalty ограничивает уход средних под влиянием выбросов; `near_centers` без penalty иногда ухудшают mean error, поскольку текущая геометрия уже могла сместиться к contamination. Сырые $n_2 = 3/5$ варианты не выигрывают.

Решение по результатам. Не заявлять общую contamination-robustness. Зафиксировать Student- t с малым ν как главный положительный сигнал. Проверить, можно ли уменьшить влияние outliers через выбор только плотных data-centered тестовых функций.

7 Эксперимент 4: density-based выбор тестовых центров

Конфиг: `moments_density_center_ablation.yaml` | каталог результатов: `moments_density_center_ablation/`.

7.1 Постановка

Для каждой точки данных вычисляется "видимость" $\sum_i K_s(X_i, c)$; центрами тестовых функций становятся только точки из верхней доли $f \in \{1.0, 0.9, 0.5, 0.3\}$. Использованы те же 12 contaminated сценариев, 8 dataset seeds и 3 model seeds. Пять moment-семейств образуют 20 вариантов; ЕМ и KMeans сохранены для прямого сравнения.

7.2 Средний эффект доли центров

f	KL ↓	TV ↓	Mean ↓	Cov ↓	ARI ↑
1.0	1.058	0.227	2.105	1.828	0.394
0.9	0.997	0.225	2.040	1.841	0.389
0.5	0.998	0.221	2.043	1.818	0.393
0.3	1.010	0.217	2.052	1.813	0.395

Пул по всем семействам показывает умеренное улучшение KL и весов, но не монотонный эффект и почти отсутствие выигрыша по ARI. Пул несколько искажён тем, что фильтрация сильно спасает отдельные нестабильные семейства.

Для наиболее сильного `stab_balanced_both`:

f	KL ↓	TV ↓	Mean ↓	Cov ↓	ARI ↑
1.0	0.867	0.223	1.732	1.862	0.414
0.9	0.908	0.218	1.734	1.882	0.404
0.5	0.889	0.214	1.749	1.851	0.413
0.3	0.882	0.212	1.740	1.863	0.414

Здесь unfiltered $f = 1$ сохраняет лучшую KL и mean error. $f = 0.3$ улучшает веса без потери среднего ARI, но не даёт общего доминирования.

7.3 Зависимость от типа contamination

По pooled Forward KL:

Тип	$f = 1.0$	$f = 0.9$	$f = 0.5$	$f = 0.3$
Radial	0.663	0.683	0.701	0.704
Student- t	1.586	1.272	1.277	1.304
Uniform	1.251	1.257	1.226	1.245
Variance	0.731	0.776	0.790	0.788

Фильтр особенно полезен для Student- t : он снижает влияние периферийных наблюдений как тестовых центров. Для radial и variance contamination удалённые центры, напротив, несут полезную информацию о несогласованности модели с данными; их исключение ухудшает KL к clean core в выбранной оптимизационной динамике. Для uniform background эффект слаб и неоднозначен.

ЕМ остаётся лидером общего рейтинга; density filtering не создаёт преимуществ moment-метода над likelihood baselines.

Решение по результатам. Не менять дефолт $f = 1.0$. Рассматривать $f = 0.9$ или 0.5 как специализированную robust-настройку для тяжёлых хвостов; $f = 0.3$ слишком агрессивен для общего применения. В будущем выбирать f адаптивно по распределению density scores, а не фиксированной долей.

8 Эксперимент 5: направленная асимметрия компонент

Конфиг: moments_directional_skewness.yaml | каталог результатов: moments_directional_skewness /.

8.1 Постановка

Directional-Gamma генератор сохраняет точные истинные средние и ковариации. В whitened координатах одна компонента residual заменяется на

$$S = \frac{G - a}{\sqrt{a}}, \quad G \sim \Gamma(a, 1),$$

а остальные направления остаются гауссовскими. При $a = 2$ стандартизованная skewness равна $2/\sqrt{2}$. Направление длинного хвоста выбирается как:

- random --- случайное для каждой компоненты;
- toward --- к барицентру смеси;
- away --- от барицентра.

Два data regimes (balanced $n = 500$ и scarce/moderately imbalanced $n = 200$) пересечены с separation 3.5/6.0 и тремя направлениями --- всего 12 сценариев. Использовано 20 dataset seeds, 3 model seeds и независимая evaluation sample размера 10 000.

8.2 Общий результат

Модель	True KL ↓	SW2 ↓	TV ↓	Mean ↓	Cov ↓	ARI ↑
EM reg 10^{-2}	0.242	0.147	0.035	0.109	0.049	0.962
EM reg 10^{-6}	0.244	0.147	0.036	0.108	0.052	0.961
Лучший moment по каждой метрике	0.283	0.153	0.050	0.132	0.084	0.942
KMeans	0.323	0.153	0.063	0.140	0.144	0.928

EM reg 10^{-2} имеет лучшую mean True KL во всех 12 сценариях. EM также выигрывает Conditional NLL в 11 из 12 и почти все parameter metrics. Energy Distance практически не различает методы (0.1582--0.1587 у лидеров) и остаётся вторичной диагностикой.

8.3 Взаимодействие sample regime и separation

Для интерпретации дополнительно вычислена oracle KL Gaussian mixture с точными истинными весами, средними и ковариациями. Это не новое обучение, а оценка неизбежной ошибки Gaussian approximation.

Режим	Oracle KL	EM KL	$n_2 = 3$ near KL	EM ARI	Moment ARI
balanced easy	0.184	0.216	0.221	0.993	0.993
balanced hard	0.171	0.202	0.222	0.947	0.945
scarce easy	0.184	0.277	0.326	0.987	0.962
scarce hard	0.173	0.275	0.376	0.921	0.863

При balanced-easy методы почти эквивалентны. Разрыв растёт при overlap и особенно при дефиците данных/неравным весам. В scarce-hard estimation excess над oracle составляет около 0.10 для EM и 0.20 для выбранной moment-модели. Предполагаемое преимущество moment-метода в failure tails не наблюдается: его variance и разрыв mean--median часто выше.

8.4 Эффект направления

В balanced-hard постановке направление работает ожидаемо:

Направление	EM ARI	$n_2 = 3$ near ARI
away	0.980	0.980
random	0.947	0.943
toward	0.914	0.912

При toward компоненты сильнее перекрываются. Одновременно True KL становится ниже: marginal density при inward tails легче приблизить смесью, даже если latent labels хуже идентифицируются. Это наглядно показывает, почему density fit и recovery компонент нельзя сводить к одной метрике.

В scarce-imbalanced режиме away тоже становится сложным: внешний хвост большой компоненты способен сместить оценивание и скрыть малую компоненту. Направление взаимодействует с весами, а не задаёт универсальный порядок сложности.

8.5 Статистические вырождения

Conditional NLL выявила редкие случаи, где ok=1, median score около 14, но mean достигает 10^6 – 10^7 . Это соответствует содержательно неудачному решению: малая истинная компонента пропущена или сопоставлена с почти вырожденной найденной компонентой. Проблема встречается в основном у нестабилизированных moment-вариантов. Mean penalty устраняет наиболее экстремальные случаи.

Решение по результатам. Гипотеза о преимуществе над EM при light-tailed directional skewness не подтверждена. Сохранить stab_balanced_both и stab_n3_w025_near; следующий тест строить как dose-response по силе skewness и как skew- t , где асимметрия сочетается с тяжёлым хвостом.

9 Сквозные выводы о работе метода

9.1 Что подтверждено

1. **Модель действительно обучается и улучшает KMeans.** В balanced-hard skewness сценариях KMeans имеет KL 0.315, moment около 0.222, EM 0.202; ARI moment почти совпадает с EM.
2. **Simplex --- правильный дефолт.** Он сохраняет интерпретацию реальной смеси и не уступает non-negative варианту систематически.
3. **Component geometry стабильнее joint geometry.** Совместная геометрия слишком чувствительна и даёт крупные ошибки средних.
4. **Mean penalty --- основной стабилизатор.** Он снижает KL, parameter error и частоту статистических вырождений.
5. **Near-mean centers полезны как дополнение.** Они улучшают локальную идентификацию, веса и иногда ARI, но без anchoring могут следовать уже смещённой геометрии.
6. **Вторые моменты полезны, но требуют баланса.** Больше направлений улучшает сырую модель; выигрыш меньше эффекта стабилизации. Умеренный вес 0.25 остаётся разумным общим выбором.
7. **Много тестовых центров лучше малого фиксированного бюджета.** Это было явно видно уже в global sweep.
8. **Density filtering не является бесплатной robustness.** Реальные хвостовые точки могут нести полезный сигнал; фильтр следует применять только под конкретную contamination model.

9.2 Что не подтверждено

- Нет общего преимущества над EM при малой чистой выборке.
- Нет общего преимущества по Gaussian-core KL при contamination.
- Нет преимущества при направленной Gamma-skewness.
- Увеличение числа вторых моментов само по себе не решает проблемы локальной оптимизации и component stealing.
- Energy Distance на training X недостаточно чувствительна для ранжирования близких моделей.

9.3 Где остаётся положительная гипотеза

Наиболее сильный сигнал --- ARI на Student- t с $\nu = 3$: moment 0.533 против EM 0.342. Это согласуется с идеей, что локализованные kernel moments могут снижать влияние тяжёлых хвостов. Directional Gamma имеет экспоненциальный, а не полиномиальный хвост и не проверяет этот механизм в полной мере.

10 Рекомендуемая следующая программа экспериментов

1. **Зафиксировать shortlist** до запуска: stab_balanced_both, stab_n3_w025_near, stab_n3_w025_both, две EM и KMeans.
2. **Skewness dose-response:** gamma_shape $\in \{0.5, 1, 2, 8\}$ плюс Gaussian calibration.

3. **Skew- t :** независимо менять degrees of freedom и силу skewness. Это прямой тест наиболее перспективной гипотезы.
4. **Adaptive density filtering:** выбирать центры по квантилям density score только при диагностированном тяжёлом хвосте; сравнить $f = 1, 0.9, 0.5$ без 0.3.
5. **Failure diagnostics:** сохранять minimum weight, minimum variance, maximum matching distance и долю Conditional NLL выше порога.
6. **Сохранять raw paired metrics**, включая dataset seed и model seed. Это позволит строить paired bootstrap intervals и разделить вариативность данных от вариативности оптимизации.
7. **Добавить Gaussian oracle строкой в результаты**, чтобы отделять approximation error от estimation error без отдельного постанализа.
8. **Развести две конечные цели:** density approximation оценивать True KL/NLL/SW2, a recovery компонент --- ARI, parameter errors и Conditional NLL. Не объединять их в один score.

11 Карта артефактов

Эксперимент	Конфигурация	Результаты
Global sweep	optimization_moments_global_sweep.yaml	optimization_moments_global_sweep/
Clean robustness	moments_robustness_ablation.yaml	moments_robustness_ablation/
Contamination	moments_contamination_robustness.yaml	moments_contamination_robustness/
Density centers	moments_density_center_ablation.yaml	moments_density_center_ablation/
Directional skewness	moments_directional_skewness.yaml	moments_directional_skewness/

Отчёт построен по финальным CSV в каталоге results/.
 Ни один эксперимент при подготовке отчёта не перезапускался.